

Tugas Praktikum Praproses Data

Malfino Muhammad Willianz - 5054251028

Dept. Teknik Informatika, Prodi Rekayasa Kecerdasan Artifisial

1. Deskripsi Dataset

Dataset yang digunakan pada praktikum ini adalah *House Prices - Advanced Regression Techniques* yang diperoleh dari Kaggle. Dataset berisi informasi penjualan rumah beserta sejumlah atribut yang menggambarkan ukuran bangunan, tahun pembangunan, kualitas material, kondisi rumah, hingga lokasi lingkungan tempat rumah berada.

Berkas yang digunakan adalah `train.csv` dengan 1.460 observasi dan 81 kolom. Atribut `Id` digunakan sebagai identitas baris, sedangkan `SalePrice` merupakan atribut target yang merepresentasikan harga jual rumah dalam satuan dolar. Tujuan tahapan praproses ini adalah menghasilkan dataset yang bersih, konsisten, dan siap digunakan untuk analisis maupun pemodelan *machine learning*.

Secara umum, atribut pada dataset dapat dikelompokkan menjadi beberapa tipe:

Kelompok Atribut	Tipe	Contoh dan Penjelasan
Id	Identifier	Nomor identitas baris dan tidak memiliki makna sebagai besaran numerik, sehingga dikeluarkan dari proses transformasi.
Atribut kategorikal	Nominal dan Ordinal	<code>MSZoning</code> , <code>Neighborhood</code> , <code>Street</code> , <code>ExterQual</code> , dan <code>KitchenQual</code> . Sebagian besar bersifat nominal, sedangkan atribut kualitas seperti <code>ExterQual</code> bersifat ordinal.
Atribut numerik	Diskret dan Kontinu	<code>LotArea</code> , <code>GrLivArea</code> , <code>YearBuilt</code> , dan <code>GarageArea</code> . Atribut ini menggambarkan besaran kuantitatif yang dapat digunakan langsung dalam perhitungan.
<code>MSSubClass</code>	Nominal	Walaupun tersimpan sebagai bilangan bulat, atribut ini merupakan kode tipe bangunan sehingga diperlakukan sebagai kategori.
<code>SalePrice</code>	Numerik Kontinu	Harga jual rumah dalam dolar dan digunakan sebagai atribut target.
<code>SaleType</code> & <code>SaleCondition</code>	Nominal	Menjelaskan jenis dan kondisi penjualan rumah, tanpa urutan alami.

2. Pemeriksaan Data Awal

Sebelum dilakukan praproses, struktur data diperiksa terlebih dahulu. Dataset memiliki 1.460 baris dan 80 atribut selain Id. Dari pemeriksaan tipe data, terdapat 38 atribut kategorikal dan 39 atribut numerik, dengan SalePrice sebagai target.

Distribusi SalePrice menunjukkan pola yang tidak simetris. Nilai rata-rata berada pada 180.921 dolar, sedangkan nilai median sebesar 163.000 dolar. Rata-rata yang lebih tinggi daripada median mengindikasikan adanya sejumlah rumah dengan harga jual yang sangat tinggi dan menarik ekor distribusi ke arah kanan.


Statistik	SalePrice (USD)
Jumlah observasi	1.460
Rata-rata	180.921
Standar deviasi	79.443
Minimum	34.900
Kuartil 1	129.975
Median	163.000
Kuartil 3	214.000
Maksimum	755.000

3. Pembersihan Data

3.1. Penanganan Nilai Hilang

Pemeriksaan nilai hilang menunjukkan bahwa dari 80 atribut, terdapat 19 atribut yang memiliki nilai kosong. Sebagian besar nilai kosong tersebut terpusat pada sejumlah kecil atribut dengan proporsi yang sangat tinggi.

Atribut	Jumlah Hilang	Persentase
PoolQC	1.453	99,52%
MiscFeature	1.406	96,30%
Alley	1.369	93,77%
Fence	1.179	80,75%
MasVnrType	872	59,73%
FireplaceQu	690	47,26%
LotFrontage	259	17,74%
GarageType	81	5,55%
BsmtQual	37	2,53%
Electrical	1	0,07%



Gambar 1: Persentase Nilai Hilang per Atribut pada Data Mentah


Penghapusan atribut dengan nilai hilang di atas 50%. Sebanyak 5 atribut memiliki proporsi nilai hilang lebih dari 50%, yaitu PoolQC, MiscFeature, Alley, Fence, dan MasVnrType. Kelima atribut tersebut dibuang karena jumlah informasi yang tersedia sangat sedikit sehingga tidak cukup andal untuk dianalisis. Setelah penghapusan, jumlah atribut berkurang dari 81 menjadi 76 atribut.

Penanganan nilai hilang pada atribut kategorikal. Untuk atribut seperti FireplaceQu, GarageType, GarageFinish, GarageQual, GarageCond, dan atribut *basement* seperti BsmtQual, BsmtCond, BsmtExposure, BsmtFinType1, serta BsmtFinType2, nilai kosong sebenarnya menandakan bahwa fasilitas tersebut tidak dimiliki oleh rumah. Oleh karena itu, nilai kosong diisi dengan kategori baru bernama None agar maknanya menjadi eksplisit. Nilai kosong tunggal pada Electrical diisi dengan nilai modus atribut.

Penanganan nilai hilang pada atribut numerik. Nilai kosong pada LotFrontage diisi menggunakan median per lingkungan (Neighborhood), karena lebar muka tanah sangat bergantung pada karakteristik tiap kawasan. GarageYrBlt diisi dengan YearBuilt, dengan asumsi garasi dibangun bersamaan dengan rumah. MasVnrArea yang kosong diisi dengan nilai 0 karena ketiadaan data pada umumnya berarti rumah tersebut tidak memiliki pelapisan batu. Setelah seluruh langkah tersebut, dataset tidak lagi mengandung nilai hilang.


3.2. Deteksi dan Penanganan Outlier

Deteksi *outlier* dilakukan pada atribut numerik menggunakan metode *Interquartile Range* (IQR), dengan batas 1,5 kali IQR di bawah kuartil pertama dan di atas kuartil ketiga. Hasil pemeriksaan menunjukkan terdapat 1.493 nilai *outlier* yang tersebar pada 29 atribut numerik.



Gambar 2: Boxplot SalePrice dan GrLivArea sebelum Penanganan Outlier

Untuk atribut GrLivArea (luas bangunan di atas tanah) ditemukan 31 observasi *outlier*. Sebagian besar *outlier* tersebut merupakan rumah berukuran sangat besar dengan harga jual tinggi, sehingga masih merupakan observasi yang valid.




Gambar 3: Hubungan GrLivArea dan SalePrice dengan Penanda Outlier IQR

Outlier pada dataset ini tidak dihapus. Alasan utamanya adalah bahwa nilai-nilai ekstrem tersebut merupakan data nyata dari proses penjualan rumah, bukan kesalahan pencatatan, dan justru mengandung informasi penting mengenai rumah berukuran besar maupun bernilai tinggi. Menghapusnya berpotensi menghilangkan pola yang relevan, terutama karena jumlah *outlier* mencapai sekitar 61% baris jika dihitung per baris.

Sebagai gantinya, dua strategi digunakan:

- *Winsorization (capping)* diterapkan pada atribut numerik selain target, yaitu nilai yang berada di luar batas IQR dipotong ke batas tersebut. Sebanyak 30 atribut mengalami proses ini sehingga pengaruh nilai ekstrem dapat dikurangi tanpa menghilangkan observasi.

- Transformasi logaritmik diterapkan pada atribut dengan kemencengan tinggi agar distribusinya lebih mendekati normal.




Gambar 4: Perbandingan Distribusi GrLivArea sebelum dan sesudah Transformasi Logaritmik
Transformasi $\log_{1p}$ menurunkan kemencengan GrLivArea dari 1,37 menjadi sekitar 0,00, sehingga distribusinya menjadi jauh lebih simetris. Pendekatan ini membantu model yang sensitif terhadap skala dan nilai ekstrem.

4. Transformasi Data

4.1. Normalisasi / Standarisasi

Langkah standarisasi dilakukan menggunakan metode *z-score* melalui `StandardScaler`, yaitu setiap atribut numerik dikurangi rata-ratanya dan dibagi dengan standar deviasinya. Proses ini diterapkan pada seluruh atribut numerik kecuali `Id` dan `SalePrice`.



Gambar 5: Distribusi GrLivArea sebelum dan sesudah Standarisasi

Standarisasi tidak mengubah bentuk distribusi, tetapi menempatkan seluruh atribut pada skala yang sebanding, yaitu berpusat pada nilai 0 dengan simpangan baku 1. Hal ini penting karena banyak algoritma seperti PCA, *k-nearest neighbor*, dan regresi dengan regularisasi menjadi sensitif apabila antar-atribut memiliki skala yang jauh berbeda (LotArea dalam puluhan ribu meter persegi dibandingkan OverallQual yang bernilai 1–10).

4.2. Encoding Atribut Kategorikal

Seluruh atribut kategorikal (sebanyak 38 atribut, termasuk MSSubClass) diubah menjadi representasi numerik menggunakan *one-hot encoding*. Setiap kategori diubah menjadi kolom biner baru yang bernilai 1 apabila kategori tersebut muncul dan 0 apabila tidak.


Setelah proses *encoding*, jumlah atribut berkembang dari 76 atribut asli menjadi 296 kolom, sedangkan jumlah baris tetap 1.460. Atribut MSSubClass ikut di-*encode* karena meskipun bertipe bilangan bulat, nilainya merepresentasikan kode kategori tipe bangunan dan bukan besaran numerik yang dapat diurutkan.

Pendekatan *one-hot* dipilih karena mayoritas atribut kategorikal bersifat nominal dan tidak memiliki urutan alami. Pemberian label angka pada atribut nominal dapat memunculkan asumsi urutan yang keliru pada model.

5. Reduksi Dimensi

5.1. Analisis Korelasi

Setelah *encoding*, dilakukan pemeriksaan korelasi antar-atribut numerik untuk mengidentifikasi atribut yang redundan. Ambang batas yang digunakan adalah korelasi absolut di atas 0,90, karena pasangan atribut dengan korelasi setinggi itu membawa informasi yang hampir sama.




Gambar 6: Matriks Korelasi Atribut Numerik Utama terhadap SalePrice

Hubungan terkuat terhadap SalePrice ditemukan pada OverallQual (0,79), GrLivArea (0,71), GarageCars (0,64), dan GarageArea (0,62). Beberapa pasangan atribut juga menunjukkan korelasi yang sangat tinggi, misalnya GarageCars dengan GarageArea, serta TotalBsmtSF dengan 1stFlrSF.

Dari hasil tersebut, sebanyak 25 atribut yang sangat berkorelasi dengan atribut lain dibuang, sehingga jumlah kolom berkurang dari 296 menjadi 271 kolom. Pembuangan ini mengurangi redundansi dan dimensi data tanpa kehilangan informasi yang berarti.


5.2. Principal Component Analysis (PCA)

Sebagai tahap reduksi dimensi lanjutan, *Principal Component Analysis* (PCA) diterapkan pada matriks fitur yang telah distandarisasi. PCA mengubah atribut-asli menjadi komponen-komponen utama yang saling tegak lurus (*orthogonal*), dengan komponen pertama menangkap varians terbesar.



Gambar 7: Scree Plot dan Cumulative Explained Variance dari PCA

Hasil PCA menunjukkan bahwa varians data tersebar pada banyak komponen, yang mengindikasikan bahwa atribut-atribut pada dataset relatif tidak saling bergantung dan masing-masing menyumbang informasi tersendiri. Komponen pertama hanya menjelaskan sekitar 6–7% varians, dan untuk mencapai 90% varians total diperlukan sekitar 144 komponen.



Gambar 8: Proyeksi Data pada Dua Komponen Utama Pertama

Ketika data diproyeksikan pada dua komponen pertama, terlihat sebagian struktur dan pengelompokan, namun SalePrice tidak terpisah secara jelas hanya berdasarkan dua komponen. Hal ini wajar mengingat informasi harga rumah tersebar di banyak atribut, sehingga dibutuhkan lebih banyak komponen untuk merepresentasikannya secara memadai.

6. Ringkasan Dataset Akhir

Setelah seluruh tahapan praproses, dataset akhir memiliki karakteristik sebagai berikut:

Tahapan	Jumlah Baris	Jumlah Kolom
Data mentah	1.460	81
Setelah hapus atribut >50% hilang	1.460	76
Setelah imputasi nilai hilang	1.460	76
Setelah winsorization & transformasi log	1.460	76
Setelah standarisasi & one-hot encoding	1.460	296
Setelah pemangkasan korelasi	1.460	271

Dataset akhir tersimpan dalam berkas 5054251028_Malfino Muhammad Willianz_Tugas_Praproses_Data.csv dengan 1.460 baris dan 296 kolom hasil *encoding*. Versi dataset yang telah dipangkas korelasinya (271 kolom) digunakan untuk analisis PCA.

Seluruh nilai hilang sudah ditangani, nilai ekstrem telah di-*winsorize* dan ditransformasi, atribut numerik telah distandarisasi, serta atribut kategorikal telah dikodekan menjadi bentuk numerik. Dengan demikian, dataset telah bersih, konsisten, dan siap digunakan untuk tahap pemodelan.

7. Kesimpulan

Berdasarkan tahapan praproses yang dilakukan, terdapat beberapa temuan utama. Dataset awal memiliki 19 atribut dengan nilai hilang, di mana 5 di antaranya melewati ambang 50% dan dibuang. Nilai hilang lainnya ditangani secara terarah sesuai makna tiap atribut, baik dengan kategori None, pengisian median per lingkungan, maupun asumsi berbasis domain.

Outlier yang terdeteksi melalui metode IQR tidak dihapus karena merupakan observasi valid, tetapi ditangani melalui *winsorization* dan transformasi logaritmik agar pengaruhnya berkurang sekaligus mempertahankan informasi. Kemencengan GrLivArea berhasil diturunkan dari 1,37 menjadi mendekati 0.

Transformasi data menghasilkan seluruh atribut numerik berskala seragam melalui standarisasi, sedangkan 38 atribut kategorikal dikodekan dengan *one-hot encoding* sehingga jumlah kolom berkembang menjadi 296. Reduksi dimensi melalui pemangkasan korelasi mengurangi 25 atribut redundan, dan PCA menunjukkan bahwa varians data tersebar pada banyak komponen sehingga 90% varians memerlukan sekitar 144 komponen. Secara keseluruhan, dataset akhir telah siap digunakan untuk analisis lanjutan maupun pemodelan *machine learning*.