

Tugas Praktikum EDA dan Scraping

Malfino Muhammad Willianz - 5054251028

Dept. Teknik Informatika, Prodi Rekayasa Kecerdasan Artificial

1. Deskripsi Dataset

Dataset yang digunakan merupakan data planet kecil (**minor planets**) yang diperoleh melalui proses **web scraping** dari Wikipedia. Pengambilan data dilakukan terhadap 5.000 planet kecil pertama, dengan halaman sumber dibagi menjadi lima rentang yang masing-masing berisi 1.000 objek.

Hasil proses scraping menghasilkan dataset dengan **5.000 observasi** dan **6 atribut**. Atribut number digunakan sebagai nomor identifikasi objek, sedangkan lima atribut lainnya digunakan dalam proses eksplorasi data, yaitu tanggal penemuan, lokasi penemuan, penemu, kategori, dan diameter objek.

Atribut	Tipe Atribut	Penjelasan
number	Identifier	Nomor katalog planet kecil. Walaupun disimpan dalam bentuk bilangan bulat, atribut ini digunakan sebagai identitas objek dan bukan sebagai besaran numerik.
discovery_date	Ordinal atau Temporal	Tanggal penemuan memiliki urutan kronologis yang jelas dan dapat diturunkan menjadi tahun, dekade, maupun bulan untuk analisis temporal.
discovery_site	Nominal	Nama lokasi atau observatorium tempat objek ditemukan dan tidak memiliki urutan alami.
discoverer	Nominal	Nama individu, kelompok, atau institusi yang tercatat sebagai penemu tanpa tingkatan atau urutan tertentu.
category	Nominal	Kategori planet kecil seperti EOS, THM, KOR, dan kategori lainnya tanpa urutan alami.
diameter_km	Numerik Kontinu	Diameter objek dalam kilometer yang dapat memiliki nilai pecahan dan memiliki makna pengukuran kuantitatif.

Sebelum analisis dilakukan, atribut `discovery_date` dikonversi menjadi tipe data tanggal. Beberapa simbol pada `category` yang merepresentasikan informasi tidak tersedia juga diubah menjadi nilai kosong agar dapat dianalisis secara konsisten.

2. Statistik Deskriptif

2.1. Atribut Numerik

Atribut numerik utama yang dianalisis adalah `diameter_km`. Dari 5.000 objek, seluruh observasi memiliki informasi diameter.

Statistik	Diameter (km)
Jumlah observasi	5.000
Rata-rata	26,84
Standar deviasi	37,36
Minimum	0,25
Kuartil 1	7,50
Median	14,00
Kuartil 3	30,00
Maksimum	939,00

Nilai rata-rata diameter sebesar 26,84 km berada cukup jauh di atas median sebesar 14 km. Perbedaan tersebut mengindikasikan distribusi yang tidak simetris dan adanya sejumlah objek dengan diameter yang jauh lebih besar dibandingkan mayoritas objek lainnya.

Tanggal penemuan dalam dataset berada pada rentang **1 Januari 1801** hingga **15 Agustus 1991**. Median tanggal penemuan berada sekitar tahun 1968, sedangkan kuartil ketiga berada sekitar tahun 1981.

2.2. Atribut Kategorikal

Dataset memiliki **132 lokasi penemuan** yang berbeda. Lokasi yang paling sering muncul adalah **Heidelberg** dengan 797 penemuan.

Atribut `discoverer` memiliki **379 nilai unik**, dengan **K. Reinmuth** sebagai entri penemu yang paling sering muncul sebanyak 373 kali.

Sebelum penanganan nilai hilang, atribut `category` memiliki 2.120 nilai yang tersedia dan mencakup **196 kategori berbeda**. Kategori yang paling sering muncul adalah **EOS** sebanyak 270 observasi.

3. Penanganan Data

3.1. Nilai Hilang

Atribut	Jumlah Missing	Persentase
<code>number</code>	0	0,00%
<code>discovery_date</code>	0	0,00%
<code>discovery_site</code>	0	0,00%
<code>discoverer</code>	0	0,00%

category	2.880	57,60%
diameter_km	0	0,00%

Analisis missing value menunjukkan bahwa hanya atribut `category` yang memiliki nilai hilang. Dari 5.000 observasi, terdapat **2.880 observasi** dengan kategori yang tidak tersedia atau sebesar **57,60%** dari keseluruhan dataset.


Karena jumlah nilai hilang mencapai lebih dari setengah dataset, penghapusan seluruh baris dengan `category` kosong tidak dilakukan. Menghapus observasi tersebut akan menyebabkan kehilangan informasi dalam jumlah yang sangat besar, termasuk informasi pada variabel lain yang sebenarnya lengkap.

Sebagai langkah penanganan, nilai kosong pada `category` dipertahankan sebagai sebuah kategori baru bernama `Unknown`. Pendekatan ini memungkinkan seluruh observasi tetap digunakan dalam analisis sekaligus mempertahankan informasi bahwa kategori asli objek tersebut tidak tersedia.

3.2. Outlier

Deteksi outlier dilakukan terhadap `diameter_km` menggunakan metode **Interquartile Range (IQR)**. Batas outlier ditentukan menggunakan aturan 1,5 kali IQR di bawah kuartil pertama dan di atas kuartil ketiga.

Hasil identifikasi menunjukkan terdapat **524 observasi** yang dikategorikan sebagai outlier. Mayoritas outlier berada pada sisi atas distribusi dan merepresentasikan planet kecil dengan diameter jauh lebih besar dibandingkan objek pada umumnya.




Gambar 1: Distribusi Diameter Planet Kecil dan Identifikasi Outlier


Outlier tersebut tidak dihapus karena objek dengan diameter sangat besar masih merupakan observasi yang valid secara domain. Sebagai gantinya, transformasi logaritmik digunakan pada beberapa visualisasi agar pola distribusi dan hubungan antarvariabel dapat terlihat lebih jelas.

4. Visualisasi dan Interpretasi

4.1. Distribusi Diameter Planet Kecil



Gambar 2: Histogram Distribusi Diameter Planet Kecil



Gambar 3: Distribusi Diameter Planet Kecil pada Skala Logaritmik


Distribusi `diameter_km` menunjukkan pola yang sangat **right-skewed**. Sebagian besar planet kecil memiliki diameter yang relatif kecil, sedangkan hanya sedikit objek yang memiliki diameter sangat besar. Kondisi tersebut menghasilkan ekor distribusi yang panjang ke arah kanan.

Boxplot menunjukkan terdapat 524 observasi yang teridentifikasi sebagai outlier berdasarkan aturan IQR, terutama pada objek dengan diameter puluhan hingga ratusan kilometer.

Ketika divisualisasikan menggunakan skala logaritmik, distribusi menjadi lebih jelas dan mendekati bentuk unimodal. Konsentrasi terbesar berada pada kisaran sekitar 10 km hingga beberapa puluh kilometer. Transformasi log membantu mengurangi dominasi nilai ekstrem sehingga pola distribusi utama lebih mudah diamati.

Hasil tersebut juga menunjukkan bahwa median lebih representatif dibandingkan rata-rata untuk menggambarkan ukuran tipikal planet kecil pada dataset.

4.2. Jumlah Penemuan per Dekade




Gambar 4: Jumlah Penemuan Planet Kecil per Dekade

Secara umum, jumlah penemuan planet kecil mengalami tren peningkatan dari abad ke-19 hingga abad ke-20. Peningkatan paling besar terlihat pada dekade 1970-an dan 1980-an.

Pola ini dapat mengindikasikan peningkatan kemampuan observasi astronomi dan berkembangnya metode survei dari waktu ke waktu.

Namun, rendahnya jumlah observasi pada dekade 1990-an tidak dapat langsung dianggap sebagai penurunan jumlah penemuan secara global. Dataset yang digunakan hanya mencakup 5.000 planet kecil pertama berdasarkan nomor katalog, sehingga distribusi temporalnya juga dipengaruhi oleh batas dataset.

4.3. Distribusi Penemuan Berdasarkan Bulan




Gambar 5: Distribusi Penemuan Planet Kecil Berdasarkan Bulan

Distribusi penemuan berdasarkan bulan menunjukkan pola yang tidak merata sepanjang tahun. Frekuensi tertinggi terjadi pada **September**, dengan jumlah mendekati 1.000 penemuan, kemudian diikuti oleh Oktober dan Agustus.


Sebaliknya, jumlah penemuan relatif rendah pada periode Mei hingga Juli, dengan titik terendah berada sekitar bulan Juni.

Pola tersebut menunjukkan indikasi **seasonality** pada waktu penemuan planet kecil dalam dataset. Akan tetapi, tingginya frekuensi pada bulan tertentu tidak dapat langsung diartikan sebagai probabilitas intrinsik planet kecil untuk ditemukan pada bulan tersebut. Pola ini juga dapat dipengaruhi kondisi cuaca, posisi objek astronomi, lokasi observatorium, serta intensitas kegiatan survei.

4.4. Lokasi Penemuan



Gambar 6: 15 Lokasi Penemuan Planet Kecil Terbanyak



Gambar 7: Persentase 15 Lokasi Penemuan Planet Kecil Teratas


Distribusi lokasi penemuan menunjukkan bahwa aktivitas penemuan cukup terkonsentrasi pada beberapa observatorium tertentu. **Heidelberg** menjadi lokasi dengan jumlah penemuan terbesar, yaitu sekitar **15,9%** dari seluruh observasi, disusul oleh **Nauchnij** sebesar **13,7%**, **Palomar** sebesar **8,6%**, dan **Anderson Mesa** sebesar **7,6%**.

Empat lokasi tersebut secara bersama-sama menyumbang hampir setengah dari keseluruhan observasi. Di sisi lain, kategori *Lainnya*, yang mencakup seluruh lokasi di luar 15 besar, masih menyumbang sekitar **24,8%**.


Hal ini menunjukkan bahwa walaupun beberapa observatorium memiliki kontribusi yang sangat besar, aktivitas penemuan tetap tersebar pada banyak lokasi lainnya.

Dominasi suatu lokasi dapat dipengaruhi kapasitas observatorium, intensitas program survei, kualitas instrumen, dan periode operasional. Oleh karena itu, hasil ini tidak dapat digunakan untuk menyimpulkan bahwa suatu lokasi secara intrinsik lebih baik untuk menemukan planet kecil.

4.5. Distribusi Penemu



Gambar 8: 15 Penemu Planet Kecil Terbanyak



Gambar 9: Persentase 15 Penemu Planet Kecil Teratas


Distribusi berdasarkan discoverer menunjukkan bahwa aktivitas penemuan lebih tersebar dibandingkan lokasi observasi. **K. Reinmuth** menjadi entri penemu dengan jumlah tertinggi dan menyumbang sekitar 7,5% dari seluruh dataset.

Posisi berikutnya ditempati oleh **N. S. Chernykh** sebesar 6,1%, **E. Bowell** sebesar 6,0%, dan **M. F. Wolf** sebesar 4,5%.

Kategori Lainnya mencapai 52,8%. Dengan demikian, 15 entri penemu teratas hanya mencakup sekitar 47,2% dari keseluruhan observasi. Hal ini menunjukkan bahwa aktivitas penemuan planet kecil tersebar pada banyak penemu.

Kolom discoverer juga tidak selalu merepresentasikan individu. Beberapa nilai merepresentasikan institusi seperti Purple Mountain dan Indiana University, sedangkan beberapa observasi mencantumkan beberapa orang sekaligus. Oleh karena itu, distribusi ini lebih tepat dipahami sebagai distribusi berdasarkan entri penemu yang tercatat pada sumber data, bukan perbandingan produktivitas individu secara langsung.

4.6. Distribusi Kategori Planet Kecil




Gambar 10: Distribusi Kategori Planet Kecil

Sebagian besar objek tidak memiliki informasi kategori, ditunjukkan oleh kelompok Unknown sebesar **57,6%**. Hal tersebut konsisten dengan hasil analisis missing value sebelumnya.

Di antara keseluruhan dataset, kategori **EOS** memiliki proporsi sekitar **5,4%**, diikuti oleh **THM** sebesar **4,9%**, serta **KOR** dan **slow** masing-masing sekitar **3,3%**. Kategori di luar kategori-kategori utama yang digabungkan menjadi Lainnya menyumbang sekitar **12,7%**.

Distribusi ini menunjukkan bahwa objek yang memiliki informasi kategori cukup beragam dan tidak didominasi secara ekstrem oleh satu kategori tertentu. Namun, karena lebih dari setengah nilai category tidak tersedia, komposisi kategori tidak dapat dianggap merepresentasikan distribusi kategori seluruh populasi planet kecil secara langsung.

4.7. Hubungan Tahun Penemuan dan Diameter



Gambar 11: Hubungan Tahun Penemuan dan Diameter Planet Kecil

Scatter plot menunjukkan adanya hubungan negatif antara tahun penemuan dan diameter planet kecil. Korelasi Spearman menghasilkan nilai $\rho = -0,53$, yang menunjukkan hubungan negatif dengan kekuatan sedang.

Artinya, planet kecil yang ditemukan pada tahun yang lebih baru cenderung memiliki diameter yang lebih kecil dibandingkan objek yang ditemukan pada periode sebelumnya.

Garis tren yang menurun memperkuat pola tersebut. Pada awal periode observasi, objek yang ditemukan umumnya memiliki diameter relatif besar. Seiring waktu, distribusi diameter menjadi lebih luas dan mencakup semakin banyak objek berdiameter kecil.

Transformasi $\log_{10}$ terhadap diameter digunakan agar pengaruh objek dengan diameter ekstrem berkurang dan hubungan antarvariabel dapat diamati dengan lebih jelas.

Pola ini dapat mengindikasikan perkembangan kemampuan observasi astronomi, di mana peningkatan sensitivitas instrumen dan metode survei memungkinkan pendeteksian objek yang lebih kecil. Namun, hubungan tersebut bersifat korelasional dan tidak menunjukkan hubungan sebab-akibat secara langsung.

5. Kesimpulan

Berdasarkan hasil eksplorasi, dataset planet kecil menunjukkan beberapa karakteristik utama. Distribusi diameter sangat menceng ke kanan dan mengandung sejumlah besar nilai ekstrem, sehingga penggunaan median dan transformasi logaritmik lebih sesuai untuk memahami pola ukuran objek.

Dari sisi temporal, jumlah penemuan meningkat secara umum menuju akhir abad ke-20, dengan pola musiman yang menunjukkan frekuensi penemuan relatif tinggi pada periode Agustus hingga Oktober.

Aktivitas penemuan cukup terkonsentrasi pada beberapa observatorium utama, tetapi lebih tersebar jika dilihat berdasarkan penemu. Selain itu, lebih dari setengah observasi tidak memiliki informasi kategori sehingga interpretasi komposisi kategori perlu dilakukan secara hati-hati.

Hubungan antara tahun penemuan dan diameter menghasilkan korelasi Spearman sebesar $-0,53$. Hal tersebut menunjukkan bahwa objek yang ditemukan pada periode yang lebih baru cenderung memiliki ukuran lebih kecil. Temuan ini konsisten dengan dugaan bahwa peningkatan kemampuan observasi memungkinkan pendeteksian objek berukuran lebih kecil, meskipun hubungan sebab-akibat tidak dapat ditentukan hanya berdasarkan EDA.